Comparaison de cinq modèles Ollama pour notre assistant RAG

Challenge Givaudan

Contexte

Notre assistant fonctionne en deux temps : il cherche d'abord des passages utiles dans ChromaDB, puis un modèle de langage utilise ces passages pour écrire la réponse. Le modèle n'a donc pas besoin de connaître le métier par cœur. Ce qui compte, c'est qu'il comprenne bien les passages qu'on lui donne, qu'il n'invente rien et qu'il dise quand l'information n'y est pas.

Aujourd'hui, seul Qwen2.5:1.5b est installé sur notre machine. Les quatre autres modèles n'ont pas encore été testés dans notre projet. La comparaison ci-dessous est donc qualitative : elle ne remplace pas des mesures réalisées sur notre ordinateur.

Ce qu'on regarde

• La fidélité des réponses aux passages récupérés.
• La capacité à reconnaître une information absente.
• La qualité du français et des résumés.
• La rapidité et la mémoire nécessaire sur nos ordinateurs.

Qwen2.5:1.5b (notre modèle actuel)

Il occupe 986 Mo sur notre machine d'après *ollama list*. Il est déjà installé et branché au prototype. Son faible poids est pratique pour avancer sans demander beaucoup de ressources. En revanche, avec 1,5 milliard de paramètres, il peut avoir plus de difficultés à synthétiser plusieurs passages ou à suivre des consignes complexes. Nous le gardons comme point de référence.

Qwen2.5:3b

Il appartient à la même famille que notre modèle actuel, mais possède environ deux fois plus de paramètres. Il devrait être plus à l'aise sur certaines synthèses, au prix d'une consommation de mémoire plus élevée. C'est un bon candidat si le 1.5b manque de précision, mais nous n'avons pas encore vérifié ce gain sur nos documents.

Llama3.2:3b

Ce modèle de Meta a une taille comparable à Qwen2.5:3b. Il permet de comparer une autre famille de modèles, notamment pour le suivi des consignes et la rédaction. Il peut demander davantage de ressources que notre modèle actuel. Sans test sur nos questions Givaudan, on ne peut pas affirmer qu'il sera meilleur.

Gemma3:1b

Ce petit modèle de Google est intéressant parce qu'il reste dans une catégorie légère, proche de notre objectif de fonctionnement local. Il peut être une alternative si l'on cherche à limiter les ressources utilisées. Mais sa petite taille peut aussi limiter les réponses qui demandent de relier plusieurs informations. Il faudra comparer sa qualité de réponse à celle de Qwen.

Phi3:mini

Ce modèle de Microsoft compte environ 3,8 milliards de paramètres. Il apporte un autre point de comparaison pour les questions de compréhension et de raisonnement sur de courts documents. En contrepartie, il est plus lourd que Qwen2.5:1.5b. Sa qualité en français et sa fidélité à nos passages restent à vérifier sur notre cas.

Ce qu'on décide pour l'instant

Nous conservons **Qwen2.5:1.5b** pour le prototype : il fonctionne déjà dans notre application, il est léger et il nous permet de continuer le développement sans changer l'environnement. Ce choix est pratique à ce stade, mais ce n'est pas encore la preuve qu'il est le meilleur modèle.

Si les réponses manquent de précision, Qwen2.5:3b et Llama3.2:3b sont des alternatives à examiner. Gemma3:1b permet de comparer une autre option légère, tandis que Phi3:mini apporte une famille supplémentaire. Nous ne changerons de modèle que si les réponses deviennent sensiblement meilleures et que le coût en mémoire et en temps reste acceptable.