Benchmark de modèles Ollama : logique et raisonnement

Cible : MacBook Pro M1 Pro, 16 Go de RAM. Recherche du 10/11/2026. Un modèle est retenu si 3 sources fiables confirment sa présence.

Synthèse

qwen3.5:9b est le meilleur choix pour le raisonnement sur 16 Go : meilleurs scores publiés, le plus léger (6,6 Go) et un contexte de 256K. **gemma4:12b** arrive juste derrière (7,7 à 8,0 Go, 256K, image et audio en plus). **gpt-oss:20b** est solide mais ses 14 Go sont trop justes sur 16 Go.

Benchmark raisonnement (5 modèles)

Modèle	Poids	Contexte	GPQA Diamond	MMLU-Pro	Maths	Verdict 16 Go
qwen3.5:9b	6,6 Go	256K	81,7	82,5	83,2 (HMMT Feb 25)	Très à l'aise
gemma4:12b	7,7 - 8,0 Go	256K	78,8 %	77,2 %	77,5 % (AIME 2026)	À l'aise
gpt-oss:20b	14 Go	128K	71,5	74,8	76,7 (HMMT Feb 25)	Trop juste (2 Go de marge)
phi4-reasoning:14b	11 Go	32K	n/d	n/d	n/d	OK, contexte limité
qwen3:14b	9,3 Go	40K	n/d	n/d	n/d	OK, plus ancien

n/d = pas de score fiable trouvé dans les sources consultées. Les scores de qwen3.5 et de gpt-oss viennent du même tableau publié par Qwen, donc comparables entre eux. Ceux de gemma4 viennent de Google, avec un protocole différent. gpt-oss-20b affiche d'autres scores GPQA selon les sources (58,6 sur sa fiche Hugging Face, 68,8 chez localllm.in), selon le réglage de raisonnement.