Étude comparative des modèles d'embeddings pour un RAG

Plateforme de commande intelligente — choix du modèle pour le prototype

Statut du document : recommandation technique pour le MVP.
Jeu de données : données synthétiques structurées : clients, produits, matières premières, commandes et demandes d'échantillons.
Important : les scores de benchmarks publics ne remplacent pas l'évaluation sur notre corpus métier. Le modèle retenu devra être validé avec le protocole d'évaluation interne décrit dans ce document.

---

1. Contexte et objectif

La plateforme de commande intelligente doit transformer une demande B2B exprimée librement en une réponse fiable et exploitable. Plutôt que de demander au client de connaître une référence, l'assistant doit comprendre des formulations telles que :

> « Je cherche un arôme mangue-passion pour une boisson protéinée, peu acide et stable. »

ou :

> « Je souhaite recommander le même produit que l'an dernier, avec une note plus fraîche. »

La solution repose sur une architecture **RAG** (*Retrieval-Augmented Generation*) :

1. La demande est convertie en vecteur par un modèle d'embeddings.
2. Les documents pertinents sont recherchés dans ChromaDB : produits, commandes, clients, matières premières et échantillons.
3. Un LLM rédige une réponse uniquement à partir du contexte récupéré.

Le modèle étudié ici est donc principalement le **modèle d'embeddings**. Son rôle est déterminant : si le mauvais produit ou la mauvaise commande est récupéré, même un bon LLM produira une réponse non fiable.

---

2. Exigences spécifiques du cas d'usage

Le modèle doit répondre à six besoins métiers et techniques.

Exigence	Exemple	Implication pour le modèle
Français et anglais	« Où est mon échantillon ? » / “What did the customer reorder?”	Embeddings véritablement multilingues
Recherche sémantique	« tropical », « mangue-passion », « fruité exotique »	Compréhension des synonymes et intentions
Références exactes	`FLV-201`, `ORD-2025-002`, `RM-FT-001`	Préserver les identifiants et mots-clés
Données mixtes	Commandes, fiches produits, matières premières, briefs	Fonctionnement sur textes courts et structurés
Exécution locale	Démonstration avec Ollama et ChromaDB	Pas de dépendance obligatoire à une API externe
Confidentialité	Données commerciales et formulations sensibles	Modèle exécutable dans un environnement maîtrisé

Le corpus est volontairement bilingue et contient des informations semi-structurées. Par exemple, une commande peut inclure à la fois un identifiant, un client, une référence produit, un statut, une date et un brief en langage naturel.

---

3. Modèles évalués / présélectionnés

3.1 `nomic-embed-text` — baseline

C’est le modèle initial fourni par le dépôt pédagogique `example-rag`. Il constitue une base de comparaison indispensable car il permet de mesurer l’amélioration réellement apportée par un autre modèle.

Points forts

- Déjà intégré au dépôt de départ ;
- Léger et simple à exécuter avec Ollama ;
- Bon choix pour établir un premier résultat fonctionnel.

Limites dans notre contexte

- Pas le choix le plus ciblé pour un corpus B2B français/anglais ;
- Moins spécialisé dans le multilingue que les options sélectionnées ;
- Risque de récupération moins précise lorsqu’un client emploie des synonymes métier, des formulations libres ou un mélange français/anglais.

Décision : conservé comme **baseline**, mais non retenu comme modèle cible du MVP.

3.2 `BAAI/bge-m3`

BGE-M3 est un modèle multilingue conçu pour la recherche dense, sparse et multi-vecteurs. Il accepte des textes longs et peut participer à une recherche hybride : recherche sémantique + recherche de mots-clés.

Points forts

- Multilingue, avec prise en charge de plus de 100 langues ;
- Long contexte ;
- Intéressant pour les identifiants, références et termes exacts grâce à une approche hybride ;
- Licence ouverte et déploiement local possible.

Limites

- La mise en œuvre de toutes ses capacités hybrides est plus complexe que la recherche dense standard du dépôt ;
- Les bénéfices de sparse / multi-vecteurs exigent une architecture plus avancée que la V1 ChromaDB du prototype ;
- Nécessite un benchmark local pour vérifier que ce surcroît de complexité produit un gain réel.

Décision : excellent candidat de comparaison et option potentielle pour une V2 hybride, mais pas le choix le plus simple pour démarrer.

3.3 `multilingual-e5-large-instruct`

Modèle d'embeddings multilingue robuste, fréquemment utilisé pour la recherche sémantique. Il fonctionne avec des préfixes d'entrée explicites, par exemple `query:` et `passage:`.

Points forts

- Bon niveau de maturité pour le retrieval multilingue ;
- Adapté aux systèmes de recherche et RAG ;
- Modèle ouvert et déployable localement.

Limites

- Gestion stricte des préfixes requise ; une mauvaise préparation des requêtes dégrade les résultats ;
- Moins pratique à intégrer tel quel dans le dépôt reposant sur Ollama ;
- Rapport qualité/simplicité moins favorable pour notre démonstrateur que Qwen3 4B.

Décision : candidat de contrôle sérieux, mais non retenu pour l'implémentation principale.

3.4 `qwen3-embedding:0.6b`

Version compacte de la gamme Qwen3 Embedding, disponible directement dans Ollama.

Points forts

- Multilingue ;
- Très accessible localement ;
- Taille Ollama d'environ 639 Mo ;

- Context window de 32K ;
- Très bon choix si les machines de l'équipe ont peu de mémoire ou pas de GPU.

Limites

- Compromis qualité par rapport à la version 4B ;
- Moins robuste sur les requêtes complexes associant plusieurs conditions : client + historique + application + nuance sensorielle.

Décision : modèle de secours et excellent choix pour des démonstrations sur machine limitée.

3.5 `qwen3-embedding:4b`

Version intermédiaire de la gamme Qwen3 Embedding, disponible dans Ollama. Elle associe capacité multilingue, instruction de recherche et taille raisonnable pour un prototype local.

Points forts

- Support de plus de 100 langues ;
- Fenêtre de contexte annoncée à 32K ;
- Embeddings configurables ;
- Modèle disponible localement via Ollama ;
- Taille d'environ 2,5 Go en quantification Ollama ;
- Meilleur compromis entre les versions 0.6B et 8B ;
- Les instructions côté requête peuvent être adaptées au besoin métier : recherche de commandes, produits, matières premières et fiches clients.

Limites

- Plus gourmand que la version 0.6B ;
- Son score final dépendra de la qualité de préparation des documents, du chunking et des métadonnées ;
- Une recherche dense seule peut être moins précise qu'une recherche hybride pour certains identifiants exacts.

Décision : modèle retenu pour le MVP, sous réserve de validation par benchmark métier.

3.6 `qwen3-embedding:8b`

Version la plus performante de la famille Qwen3 Embedding sur les résultats publics communiqués par son éditeur.

Points forts

- Meilleure performance publique de la gamme ;
- Très bonne couverture multilingue ;
- Pertinent pour une industrialisation si les ressources GPU sont disponibles.

Limites

- Environ 4,7 Go en version Ollama quantifiée, avec davantage de RAM/VRAM nécessaire en utilisation ;

- Latence et coûts matériels plus élevés ;
- Surdimensionné pour un corpus synthétique limité et une démonstration de faisabilité.

Décision : option d'évolution, non retenue pour la V1.

---

4. Comparaison des benchmarks publics

Les scores ci-dessous proviennent des informations publiées par les fournisseurs et model cards. Ils servent à **présélectionner** des modèles ; ils ne constituent pas un benchmark propre à notre jeu de données.

Modèle	Taille / paramètres	Langues	MTEB multilingue — score moyen (publication)	Déploiement local	Rôle dans notre étude
`nomic-embed-text`	Modèle compact	Multilingue limité selon l'usage	Non utilisé comme référence comparative dans cette étude	Oui, Ollama	Baseline
BGE-M3	~0,6B	100+	59,56*	Oui	Comparateur hybride
multilingual-e5-large-instruct	~0,6B	Multilingue	63,22*	Oui	Comparateur instruct
Qwen3 Embedding 0.6B	0,6B	100+	64,33	Oui, Ollama	Alternative légère
Qwen3 Embedding 4B	**4B**	**100+**	**69,45**	**Oui, Ollama**	**Modèle retenu MVP**
Qwen3 Embedding 8B	8B	100+	70,58	Oui, Ollama	Option qualité maximale

* Scores rapportés dans la table comparative de la model card Qwen3, dont les protocoles exacts peuvent varier selon les modèles. Ils doivent être interprétés avec prudence.

Lecture des résultats publics

1. La famille Qwen3 présente une progression cohérente avec la taille du modèle : 0.6B → 4B → 8B.
2. Qwen3 4B se situe très près de la version 8B sur le score multilingue annoncé, tout en restant bien plus léger.
3. Pour notre cas, la différence entre les modèles doit être mise en regard de la contrainte réelle : un prototype local doit répondre rapidement, sur une machine disponible à l'équipe.
4. Un score MTEB élevé ne garantit pas à lui seul le meilleur résultat sur des références commerciales, des commandes et des descriptions sensorielles. D'où la nécessité du benchmark interne.

---

5. Modèle retenu : `qwen3-embedding:4b`

Décision

> Nous retenons **`qwen3-embedding:4b`** comme modèle d'embeddings principal du MVP RAG de la plateforme de commande intelligente.

Justification

1. Meilleur équilibre entre qualité et ressources

La version 4B est nettement plus performante que la 0.6B dans les benchmarks publics de la famille Qwen3, sans nécessiter les ressources plus élevées de la version 8B. Elle est donc cohérente avec une preuve de faisabilité locale.

2. Compatibilité avec le corpus

Notre jeu de données comporte :

- des descriptions en français et en anglais ;
- des briefs clients non structurés ;
- des caractéristiques sensorielles ;
- des références produits et commandes ;
- des informations réglementaires courtes ;
- des demandes de réassort fondées sur l'historique.

Le support multilingue et la recherche sémantique instruction-aware de Qwen3 4B sont adaptés à cette diversité.

3. Compatibilité technique avec le dépôt fourni

Le repository de départ utilise déjà :

- **Ollama** pour les embeddings et la génération ;
- **ChromaDB** pour stocker les vecteurs ;
- **FastAPI** pour exposer l'API.

Qwen3 Embedding est directement disponible dans Ollama. Son intégration demandera principalement de modifier la variable :

```
EMBED_MODEL=qwen3-embedding:4b
```

puis de supprimer et réindexer ChromaDB. Les vecteurs issus de deux modèles différents ne doivent jamais être mélangés dans la même collection.

4. Protection et maîtrise des données
Le modèle fonctionne localement. C'est un avantage pour un contexte B2B où les informations de commande, les préférences client et les informations produit doivent rester maîtrisées. La démonstration n'utilisera toutefois que des données synthétiques.

---

6. Configuration recommandée du MVP

```
LLM_MODEL=qwen2.5:1.5b
EMBED_MODEL=qwen3-embedding:4b
CHUNK_SIZE=800
TOP_K=5
```

Commandes d'installation

```
ollama pull qwen3-embedding:4b
ollama pull qwen2.5:1.5b
```

Réindexation obligatoire

```
python clean.py
python ingest.py givaudan_data.txt
python list.py
python api.py
```

Sous PowerShell :

```
$env:EMBED_MODEL="qwen3-embedding:4b"
python clean.py
python ingest.py givaudan_data.txt
python api.py
```

---

7. Protocole de benchmark interne

Objectif

Comparer la performance réelle des modèles sur nos documents et nos questions métier, et non uniquement sur un benchmark générique.

Modèles comparés

1. `nomic-embed-text` — baseline obligatoire ;
2. `qwen3-embedding:0.6b` — alternative légère ;
3. `qwen3-embedding:4b` — modèle candidat principal ;

4. `bge-m3` — comparaison complémentaire si l'environnement local le permet.

Jeu de test

Préparer au minimum **30 requêtes**, idéalement 50 à 100, réparties comme suit :

Type de requête	Exemple
Recherche produit	« Je cherche un arôme mangue-passion pour boisson protéinée. »
Recherche de commande	« Que commandait NutriPeak Foods en février 2025 ? »
Recherche client	« Quels produits a déjà testés Atelier Botanique ? »
Suivi d'échantillon	« Où en est l'échantillon de l'Atelier Botanique ? »
Matière première	« Quelle matière première apporte une note de gingembre fraîche ? »
Recherche par référence	« Donne-moi les informations sur FLV-201. »
Recherche bilingue	"What did Northstar Beverages reorder in September 2025?"
Question sans réponse	« Quel produit combine café et fraise ? »

Métriques

Mesure	Ce qu'elle mesure	Cible MVP indicative
Recall@1	Bonne source au premier résultat	≥ 0,70
Recall@3	Bonne source dans les trois premiers résultats	≥ 0,85
Recall@5	Bonne source dans les cinq premiers résultats	≥ 0,90
MRR	Position moyenne de la première bonne source	La plus haute possible
Latence moyenne	Temps de recherche par requête	À comparer selon machine
Taux de réponses non fondées	Réponses sans source pertinente	Le plus faible possible

Règle de sélection finale

Le modèle final sera confirmé s'il :

1. atteint le meilleur ou le deuxième meilleur **Recall@5** ;
2. présente un **MRR** supérieur à la baseline ;
3. reste utilisable avec les ressources de l'équipe ;
4. répond correctement aux requêtes françaises et anglaises ;
5. ne dégrade pas la recherche par référence exacte.

---

8. Limites et mesures de fiabilité

Limites

- Les benchmarks publics ne reflètent pas entièrement le vocabulaire parfum/arômes ;
- Le corpus de démonstration est synthétique et de faible taille ;
- Une recherche vectorielle seule peut confondre des produits proches ;
- Un LLM peut halluciner s'il n'est pas strictement contraint par le contexte récupéré.

Mesures recommandées

- Répondre uniquement à partir des passages récupérés ;
- Afficher les identifiants source : commande, référence produit, échantillon ;
- Répondre « information non disponible dans les données » si le contexte ne suffit pas ;
- Séparer les données par client avant une industrialisation ;
- Ajouter des filtres de métadonnées par client, pays et type de document ;
- Prévoir une recherche hybride (BM25 + vectorielle) en V2 pour les références exactes ;
- Ne jamais indexer de formules propriétaires ou de données personnelles dans une démonstration publique.

---

9. Conclusion

Le projet a besoin d'un modèle d'embeddings capable de relier des demandes client naturelles à des données B2B complexes : produits, historiques de commandes, échantillons, matières premières et contraintes métier.

`nomic-embed-text` est maintenu comme baseline car il est déjà intégré au dépôt pédagogique. Toutefois, **`qwen3-embedding:4b` est retenu pour le MVP** car il constitue le meilleur compromis entre :

- performance multilingue ;
- compréhension sémantique ;
- compatibilité avec les demandes françaises et anglaises ;
- intégration simple via Ollama ;
- exécution locale ;
- consommation de ressources compatible avec une preuve de faisabilité.

La décision sera ensuite consolidée par le benchmark interne sur le dataset généré. Si le gain observé par rapport à la version 0.6B est faible sur la machine de démonstration, cette dernière pourra devenir l'alternative de repli. Si la précision des références exactes devient prioritaire à grande échelle, BGE-M3 et une architecture de recherche hybride seront les pistes d'évolution à privilégier.

Sources

1. **Repository pédagogique RAG** — `hmicn/example-rag`, architecture FastAPI + Ollama + ChromaDB, consulté en novembre 2026 : https://github.com/hmicn/example-rag
2. **Qwen3 Embedding model card** — caractéristiques, exemples d'instruction et scores publiés de la gamme Qwen3 Embedding : https://huggingface.co/Qwen/Qwen3-Embedding-0.6B
3. **Ollama library — qwen3-embedding** — versions locales 0.6B, 4B et 8B : https://ollama.com/library/qwen3-embedding
4. **BGE-M3 model card** — modèle multilingue dense, sparse et multi-vecteurs : https://huggingface.co/BAAI/bge-m3
5. **MTEB** — cadre d'évaluation général des modèles d'embeddings : https://github.com/embeddings-benchmark/mteb